## vlm

#### pretrain

- 1.tokenizer
- 2.dataset

基于 llava,原理文章很多,且较容易。本文主要负责代码调试,明晰细节。

本文项目基于 Ilava: https://github.com/dvlabresearch/MGM

# pretrain

#### 1.tokenizer

断点位于以下代码处: if model\_args.version == "v0":

查看 tokenizer 的 special token,由于 unk 和 pad 都有,因此不需要做什么处理

除此之外,以及 dataset 部分,如果需要自定义模型几乎不需要 修改什么

#### 2.dataset

```
断点打在 dataset 的 ___getitem__ 函数
```

```
Python
   image.shape: torch.Size([3, 768, 768])
进入 preprocess_multimodal 函数
原数据: [[{'from': 'human', 'value': 'What is i
n the photo?\n<image>'}, {'from': 'gpt', 'valu
e': 'the box chain purse black'}]]
返回: [[{'from': 'human', 'value': '<image>\nWha
t is in the photo?'}, {'from': 'gpt', 'value':
'the box chain purse black'}]]
preprocess multimodal 函数只将 \n<image> 移至最前
为 <image>\n
```

进入 preprocess 函数

进入 preprocess\_gemma 函数

1.应用模版

```
Python
    print(conv)
 1
    Conversation(system='', roles=('user', 'model'), messages=[], offset=0, se
     p_style=<SeparatorStyle.GEMMA: 7>, sep='', sep2='<eos>', version='gemma',
     skip next=False)
3
4
    # 指定身份
5
    print(roles)
    {'human': 'user', 'gpt': 'model'}
 6
7
8
    print(source)
    [{'from': 'human', 'value': '<image>\nWhat is in the photo?'}, {'from': 'g
9
    pt', 'value': 'the box chain purse black'}]
10
    # conv.messages包含了纠正身份的对话
11
12
     print(conv)
    Conversation(system='', roles=('user', 'model'), messages=[['user', '<imag</pre>
13
     e>\nWhat is in the photo?'], ['model', 'the box chain purse black']], offs
     et=0, sep_style=<SeparatorStyle.GEMMA: 7>, sep='', sep2='<eos>', version=
     'gemma', skip_next=False)
```

应用对话模版: conversations.append(conv.get\_prompt())

进入: elif self.sep\_style == SeparatorStyle.GEMM A:

### 拼接后的对话为

```
print(ret)
continuous print(ret)
print(ret)
continuous print(
```

2.tokenize 部分: if has\_image:

进入函数 tokenizer\_image\_token

```
Python
1
   print(prompt chunks)
2
    [[2, 106, 1645, 108], [2, 108, 1841, 603, 575, 573, 2686, 235336, 107, 108,
    106, 2516, 108, 1175, 3741, 9488, 45189, 2656, 107, 108, 1]]
3
   tokenizer("<start of turn>user\n").input ids
4
5
   [2, 106, 1645, 108]
6
7
   tokenizer("What is in the photo?<end of turn>\n<start of turn>model\nthe bo
   x chain purse black<end of turn>\n<eos>").input ids
   [2, 1841, 603, 575, 573, 2686, 235336, 107, 108, 106, 2516, 108, 1175, 3741
    , 9488, 45189, 2656, 107, 108, 1]
```

相当于在 <image> 处进行了拆分

通过 insert\_separator 函数

```
python |

input_ids
[2, 106, 1645, 108, -200, 108, 1841, 603, 575, 573, 2686, 235336, 107, 108, 106, 2516, 108, 1175, 3741, 9488, 45189, 2656, 107, 108, 1]
```

相当于在 prompt\_chunks 间插入了 image token

id -200, 同时删除第二个 chunk 的句首 token

返回的 shape 为: torch.Size([1, 25]), 复制一份作为 targets

3.mask

```
Python
 1
    input_ids
2 * tensor([[
                 2, 106,
                              1645,
                                      108, -200,
                                                      108,
                                                            1841,
                                                                     603,
      575,
                                      107,
3
                573,
                      2686, 235336,
                                              108,
                                                      106,
                                                            2516,
                                                                     108,
     1175,
                                                               1]])
               3741,
                      9488, 45189,
                                     2656,
                                              107,
4
                                                      108,
5
6
    targets
7 tensor([[ -100, -100, -100, -100, -100, -100, -100, -100,
                                                                  -100,
    100,
              -100, -100, -100, -100, -100, -100, -100, 1175, 3741, 9
8
    488,
                                           1]])
9
             45189, 2656, 107,
                                  108,
10
11
    tokenizer("the box chain purse black<end_of_turn>\n<eos>").input_ids
12
    [2, 1175, 3741, 9488, 45189, 2656, 107, 108, 1]
```

只保留 the box chain purse black<end\_of\_turn>\n<e os> 这一部分

插值将 image 变为 torch.Size([3, 336, 336])